

# Blatt 8

Montag, 25. Juni 2018

15:43

## Aufgabe 4

a) zu zeigen:  
 $h: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $h(x,y) := \sum_{i=1}^n x_i y_i$  ist positiv semi definites Kernel

Beweis

1) Symmetry

$$h(x,y) = \sum_{n=1}^m x_n \cdot y_n = \sum_{n=1}^m y_n \cdot x_n = h(y,x) \quad \blacksquare$$

2) zu zeigen:  
 $\forall c_1, \dots, c_m \in \mathbb{R}: \sum_{i,j=1}^m c_i c_j h(x_i, x_j) \geq 0$   
mit  $h(x,y) = \sum_{k=1}^n x_k \cdot y_k$

Beweis

$$\begin{aligned} & \sum_{i,j=1}^m c_i c_j \left( \sum_{k=1}^n x_{i,k} \cdot x_{j,k} \right) \\ &= \sum_{i,j=1}^m c_i c_j h(x_i, x_j) \\ &= (c_1, \dots, c_m) \cdot \begin{pmatrix} h(x_1, x_1) & \dots & h(x_1, x_m) \\ \vdots & \ddots & \vdots \\ h(x_m, x_1) & \dots & h(x_m, x_m) \end{pmatrix} \cdot \begin{pmatrix} c_1 \\ \vdots \\ c_m \end{pmatrix} = c^T U c \end{aligned}$$

Angenommen:  $U = B^T \cdot B$  dann  $c^T U c = c^T B^T B c = (B \cdot c)^T \cdot B c = \|B c\|^2 \geq 0$

Beweis für  $U = B^T B$ :

$$\begin{pmatrix} h(x_1, x_1) & \dots & h(x_1, x_m) \\ \vdots & \ddots & \vdots \\ h(x_m, x_1) & \dots & h(x_m, x_m) \end{pmatrix} = \begin{pmatrix} x_1^T x_1 & \dots & x_1^T x_m \\ \vdots & \ddots & \vdots \\ x_m^T x_1 & \dots & x_m^T x_m \end{pmatrix} = \begin{pmatrix} x_1^T \\ \vdots \\ x_m^T \end{pmatrix} \cdot (x_1 \dots x_m) \quad \blacksquare$$

Mit 1) und 2) ist gezeigt, dass  $h(x,y) := \sum_{i=1}^n x_i y_i$   
ein positiv semi-definierter Kernel ist.  $\blacksquare$

zu zeigen:

b) zu zeigen:  $h: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $h(x,y) := \left( \sum_{i=1}^n x_i y_i \right)^2$  ist positiv semi definites Kernel

Beweis

1) Symmetry

$$h(x,y) = \left( \sum_{i=1}^n x_i y_i \right)^2 \stackrel{a)}{=} \left( \sum_{i=1}^n y_i x_i \right)^2 = h(y,x)$$

2) zu zeigen:  $\forall c_1, \dots, c_m \in \mathbb{R}: \sum_{i,j=1}^m c_i c_j h(x_i, x_j) \geq 0$   
mit  $\sum_{i,j=1}^m c_i c_j \left( \sum_{k=1}^n x_{i,k} x_{j,k} \right)^2 \geq 0$

c) zu zeigen:  $h(x,y)^d$  ist ein Kernel.

Beweis:  $h(x,y)^d = \prod_{i=1}^d h(x,y)$

$\Rightarrow$  durch den 2. Satz von dem Übungsblatt  
(Produkt von Kernel = Kernel) ist gezeigt, dass  
 $h(x,y)^d$  ein Kernel ist

d) zu zeigen:  $\sum_{i=0}^n c_i \cdot h^i$  ist ein Kernel.

Beweis:  $h_1$  ist ein Kernel  $\Rightarrow \langle \phi(x), \phi(y) \rangle = h_1(x,y)$

$$\begin{aligned} 1) \quad a \cdot h_1(x,y) &= a \cdot \langle \phi(x), \phi(y) \rangle \\ &= \sqrt{a} \cdot \sqrt{a} \cdot \langle \phi(x), \phi(y) \rangle \\ &= \langle \sqrt{a} \cdot \phi(x), \sqrt{a} \cdot \phi(y) \rangle \\ &= \langle f(x), f(y) \rangle \quad \text{mit } f(x) := \sqrt{a} \cdot \phi(x) \\ &= h_2(x,y) \end{aligned}$$

In Aufgabe 4c haben wir bewiesen, dass  $h(x,y)^i$  ein Kernel ist.

In 1) haben wir gezeigt  $a \cdot h(x,y)^i$  ein Kernel ist.

Die Summe  $\sum_{i=0}^n$  über Kernel ergibt aus dem 1. Satz von dem Übungsblatt einen Kernel.

$\Rightarrow$  Somit ist bewiesen, dass  $\sum_{i=0}^n c_i \cdot h(x,y)^i$  ein Kernel ist

Übungsblatt 1<sup>1=0</sup> über Kernel.  $\cup$

$\Rightarrow$  Somit ist bewiesen, dass  $\sum_{i=0}^n c_i \cdot k(x_i, y)$  ein Kernel ist.  $\blacksquare$

e) zu zeigen:  $(x, y) \mapsto f(x) k(x, y) f(y)$  ist ein Kernel

$$\begin{aligned} \text{Beweis: } f(x) k(x, y) f(y) &= f(x) \langle \phi(x), \phi(y) \rangle f(y) \\ &= \langle f(x) \phi(x), f(y) \phi(y) \rangle \quad \text{mit } a(x) := f(x) \cdot \phi(x) \\ &= \langle a(x), a(y) \rangle \\ &= k(x, y) \quad \blacksquare \end{aligned}$$

## Aufgabe 1

zu zeigen: 2 Datenpunkte genügen um die Hyperebene mit maximaler Margin zu finden

Beweis: Gegeben bei einer SVM ist das folgende Minimierungsproblem. Da nur 2 Punkte (mit unterschiedlicher Klasse) im Set enthalten sind, soll die Margin für diese Punkte genau 1 bzw. -1 sein

$$\arg \min \frac{1}{2} \|\omega\|^2$$

$$\omega^T x_1 + b = 1 \quad (1)$$

$$\omega^T x_2 + b = -1 \quad (2)$$

Die dazugehörige Lagrangefunktion lautet

$$L(\omega, b, \lambda_1, \lambda_2) = \frac{1}{2} \|\omega\|^2 + \lambda_1 (\omega^T x_1 + b - 1) + \lambda_2 (\omega^T x_2 + b + 1)$$

Bilde nun die dazugehörige Ableitungen:

$$\frac{\partial L(\omega, b, \lambda_1, \lambda_2)}{\partial \omega} = \omega + \lambda_1 x_1 + \lambda_2 x_2 = 0 \quad (3)$$

$$\frac{\partial L(\omega, b, \lambda_1, \lambda_2)}{\partial b} = \lambda_1 + \lambda_2 = 0 \Rightarrow \lambda_1 = -\lambda_2 \quad (4)$$

Durch Einsetzen von (3) in (4) erhält man:

$$\omega + \lambda_1 (x_1 - x_2) = 0 \Leftrightarrow \omega = -\lambda_1 (x_1 - x_2) \quad (5)$$

Durch Addition von (1) und (2) erhält man:

$$\omega^T (x_1 + x_2) + 2b = 0 \Leftrightarrow 2b = -\omega^T (x_1 + x_2)$$

$\Rightarrow$  Man sieht, dass  $\lambda_1$  in (3) nicht genauer bestimmt werden kann.  $\lambda_1$  ist jedoch nur ein Skalar.  $\lambda_1$  ändert somit nicht die Ordnung von  $\omega$ . D.h. die Lage der Hyperline ist komplett bestimmt, nur die Skalierung nicht.  $\blacksquare$

## Aufgabe 2

zu zeigen: 2 Datenpunkte genügen um die Hyperebene mit maximaler Margin zu finden und  $\gamma > 0$  verändert das Ergebnis nicht, sodass  $y_n(\omega^T \phi(x_n) + b) \geq \gamma$  mit  $n=1, \dots, N$   $\gamma > 0$

Beweis: Gegeben bei einer SVM ist das folgende Minimierungsproblem. Da nur 2 Punkte (mit unterschiedlicher Klasse) im Set enthalten sind, soll die Margin für diese Punkte genau  $\gamma$  bzw.  $-\gamma$  sein

$$\arg \min \frac{1}{2} \|\omega\|^2$$

$$\begin{aligned} \omega^T x_1 + b &= \gamma & (1) \\ \omega^T x_2 + b &= -\gamma & (2) \end{aligned} \quad \text{mit } \gamma > 0$$

Die dazugehörige Lagrangefunktion lautet

$$L(\omega, b, \lambda_1, \lambda_2) = \frac{1}{2} \|\omega\|^2 + \lambda_1 (\omega^T x_1 + b - \gamma) + \lambda_2 (\omega^T x_2 + b + \gamma)$$

Bilde nun die dazugehörige Ableitungen:

$$\frac{\partial L(\omega, b, \lambda_1, \lambda_2)}{\partial \omega} = \omega + \lambda_1 x_1 + \lambda_2 x_2 = 0 \quad (3)$$

$$\frac{\partial L(\omega, b, \lambda_1, \lambda_2)}{\partial b} = \lambda_1 + \lambda_2 = 0 \Rightarrow \lambda_1 = -\lambda_2 \quad (4)$$

Durch Einsetzen von (3) in (4) erhält man:

$$\omega + \lambda_1 (x_1 - x_2) = 0 \Leftrightarrow \omega = -\lambda_1 (x_1 - x_2) \quad (5)$$

Durch Addition von (1) und (2) erhält man:

$$\omega^T (x_1 + x_2) + 2b = \gamma + (-\gamma) = 0 \Leftrightarrow 2b = -\omega^T (x_1 + x_2)$$

$\Rightarrow$  Man sieht, dass  $\gamma$  keinen Einfluss auf das Ergebnis hat.

